


逢 甲 大 學

自 動 控 制 工 程 學 系

碩 士 論 文

基於影像特徵強化與深度學習的 AOI 瑕疵
檢測系統

AOI Defect Inspection System Based on Image Feature
Enhancement and Deep Learning



指導教授：廖本義 博士
研 究 生：鄭人龍

中 華 民 國 一 百 一 十 四 年 六 月

中文摘要

薄膜電晶體液晶顯示器 (Thin-Film Transistor Liquid-Crystal Display, TFT-LCD) 是當今眾多電子產品中的關鍵顯示元件。其製造製程極為精密，即便微小的瑕疵亦可能對最終產品的品質造成嚴重影響。傳統的檢測系統常因光線照射不均等因素而影響辨識準確率，難以有效應對 TFT-LCD 玻璃上複雜多樣的瑕疵類型。

為改善上述問題並提升 TFT-LCD 玻璃的瑕疵檢測效能，本研究提出一種影像特徵強化與深度學習的 AOI (Automated Optical Inspection) 瑕疵檢測系統。此系統首先透過影像增強技術優化影像的亮度與對比特徵，提升整體影像品質與系統辨識能力。同時，導入多元影像融合技術，整合來自不同影像來源的特徵資訊，相較於單一影像來源，多元影像數據能提供更為全面且關鍵的資訊，進而大幅強化檢測系統的穩定性與準確性。最後，本研究利用多核心深度學習模型在大型標註數據集上進行訓練，實現了 TFT-LCD 玻璃瑕疵的自動化檢測。實驗結果顯示，本研究所建構的系統在多數測試情境中皆能維持穩定效能，並具備即時處理能力與良好的辨識準確度，展現出應用於實際產線檢測的巨大潛力。綜上所述，本研究提出的瑕疵檢測技術可有效支援 TFT-LCD 製程的自動化作業，並具備實務應用價值與持續發展的可能性。

關鍵詞：TFT-LCD、AOI 瑕疵、深度學習、多元影像融合、影像增強

Abstract

Thin-Film Transistor Liquid-Crystal Displays (TFT-LCDs) are crucial display components in many modern electronic products. Their manufacturing processes are extremely precise, and even minute defects can severely impact the quality of the final product. Traditional inspection systems often suffer from inconsistent lighting conditions, which compromise their recognition accuracy and make it challenging to effectively handle the diverse and complex defect types found in TFT-LCD glass.

To address these issues and enhance the defect detection performance for TFT-LCD glass, this study proposes an Automated Optical Inspection (AOI) defect detection system that integrates image feature enhancement and deep learning. This system first employs image-enhancement techniques to optimize the brightness and contrast characteristics of images, thereby improving overall image quality and the system's recognition capabilities. Simultaneously, it incorporates multi-image fusion technology to integrate feature information from various image sources. Compared to single-source image data, multi-image data provides more comprehensive and critical information, significantly strengthening the detection system's stability and accuracy. Finally, this study uses a multi-core deep learning model trained on a large annotated dataset to achieve high-precision automated defect detection for TFT-LCD glass. Experimental results indicate that the developed system maintains stable performance across most testing scenarios, possesses real-time processing capabilities, and demonstrates excellent recognition accuracy. This highlights its significant potential for application in actual production line inspection. In conclusion, the defect detection technology proposed in this study effectively supports the automation of TFT-LCD manufacturing processes, offering practical application value and possibilities for continued development.

Keywords: TFT-LCD、AOI Defects、Deep Learning、Multi-Image Fusion、Image Enhancement

目錄

中文摘要	II
ABSTRACT	III
目錄	IV
圖目錄	VI
表目錄	VII
第一章 緒論	1
1.1 研究背景及動機	1
1.2 研究目的	3
1.3 研究原創性、創新性	4
第二章 文獻回顧	6
2.1 機器學習	6
2.2 深度學習	7
2.3 多元影像融合	9
第三章 研究方法	14
3.1 研究架構	14
3.2 影像擷取收集	15
3.3 影像增強	17
3.4 多元影像融合	20
3.5 卷積神經網路(CONVOLUTIONAL NEURAL NETWORK, CNN)	22
3.5.1 MOBILENETV3網路	25
3.5.2 訓練數據集	25
3.6 評估指標	30
3.6.1 準確率(ACCURACY)	30
3.6.2 精確率(PRECISION)	30
3.6.3 召回率(RECALL)	30
3.6.4 F1-SCORE	30
3.7 混淆矩陣	31
第四章 研究成果	33
4.1 實驗設備	33
4.2 影像增強處理	33
4.2.1 影像增強預處理	33
4.2.2 影像增強訓練結果	34
4.3 影像融合處理	38

基於影像特徵強化與深度學習的 AOI 瑕疵檢測系統	
4.3.1 影像融合預處理	38
4.3.2 影像融合訓練結果	39
4.4 訓練實驗結果	43
第五章 結論	46
第六章 未來工作	47
參考文獻	48



圖目錄

圖2-1 物流包裝箱瑕疵檢測架構圖[25].....	7
圖2-2 變電所設備瑕疵檢測架構圖[26].....	8
圖2-3 基於生成對抗網路（GAN）和 YOLO 算法的內部螺紋瑕疵檢測系統[27]	9
圖2-4 多感測器輕量級檢測網路（MLDN）架構圖[28]	10
圖2-5 PCB 瑕疵檢測模型架構圖[29].....	11
圖2-6 多感測器和多尺度模型架構圖[30].....	12
圖2-7 基於多感測器 ACNN 方法的架構圖[31].....	13
圖3-1 實驗架構圖.....	14
圖3-2 影像瑕疵的種類.....	16
圖3-3 影像特徵增強流程圖	19
圖3-4 CNN 基本架構圖[33].....	22
圖3-5 MobileNetV3 架構模組（MobileNetV3-block） [35]	26
圖3-6 Squeeze-and-Excitation 注意力機制 [36].....	28
圖4-1 影像增強結果.....	34
圖4-2 影像增強的訓練結果.....	34
圖4-3 EPOCHS 200 BATCH_SIZE 32 LEARNING_RATE 0.01	35
圖4-4 EPOCHS 300 BATCH_SIZE 32 LEARNING_RATE 0.01	36
圖4-5 EPOCHS 400 BATCH_SIZE 32 LEARNING_RATE 0.01	36
圖4-6 EPOCHS 500 BATCH_SIZE 32 LEARNING_RATE 0.01	37
圖4-7 影像融合過程.....	38
圖4-8 影像融合的訓練結果.....	39
圖4-9 EPOCHS 200 BATCH_SIZE 32 LEARNING_RATE 0.01	40
圖4-10 EPOCHS 300 BATCH_SIZE 32 LEARNING_RATE 0.01	41
圖4-11 EPOCHS 400 BATCH_SIZE 32 LEARNING_RATE 0.01	41
圖4-12 EPOCHS 500 BATCH_SIZE 32 LEARNING_RATE 0.01	42

表目錄

表3- 1 MobileNetV3模型結構 [35]..... 29

表3- 2 混淆矩陣..... 31

表3- 3 本研究實際應用之混淆矩陣示意圖..... 32

表4- 1 原始影像的訓練結果..... 43

表4- 2 影像增強的訓練結果..... 44

表4- 3 影像融合的訓練結果..... 44

表4- 4 模型於各影像處理階段之效能評估結果..... 45



第一章 緒論

本章將說明本研究的背景與研究動機，進一步明確本研究的主要目的，並說明其原創性與技術創新之處，以作為後續章節探討之基礎。

1.1 研究背景及動機

現今，薄膜電晶體液晶顯示器（Thin-Film Transistor Liquid-Crystal Display, TFT-LCD）已廣泛應用於日常生活中，成為智慧型手機、電視、電腦顯示器與筆記型電腦等設備中不可或缺的顯示技術。該類顯示器不僅具備呈現細緻高品質視覺效果的能力，更滿足了現代消費者對美學與實用性的多重需求。

儘管 TFT-LCD 技術在顯示器製造領域已有顯著進展，製造過程中仍不可避免地會出現表面瑕疵。這些瑕疵將直接影響產品的運作效能與使用壽命，並對整體良率與品質穩定性造成挑戰。由於 TFT-LCD 製程高度複雜且精密，瑕疵檢測成為確保產品一致性與可靠性的關鍵一環。

傳統瑕疵檢測方法多仰賴人工目視，容易受限於人員主觀判斷與操作疲勞，不僅耗費時間與人力，也影響檢測結果之穩定性與準確性。隨著自動化製造技術的發展，自動光學檢查（Automated Optical Inspection, AOI）逐漸被導入於各製程階段，藉由機器視覺系統與影像處理技術，達成非接觸式、高效率的瑕疵檢測。

近年來，深度學習（Deep Learning, DL）技術，特別是以卷積神經網路（Convolutional Neural Network, CNN）為代表的模型架構持續發展，使得 AOI 系統可進一步提升對瑕疵特徵的辨識能力與分類準確率。透過自動特徵學習與分類模型的建構，系統能即時分析並

回報潛在缺陷，有助於優化生產流程與提升產品良率[1-4]。

目前 AOI 系統與瑕疵檢測技術已廣泛應用於 TFT-LCD 面板、半導體晶圓、印刷電路板（Printed Circuit Board, PCB）及其他精密製造產線中。以 TFT-LCD 為例，透過瑕疵檢測系統可即時發現微小缺陷並防止不良品流入後段製程，有效提升品質控制效率。此外，AOI 系統亦可整合至智慧製造監控平台，進行缺陷統計與製程優化，協助企業達成智慧工廠與品質追溯目標[5,6]。

隨著產線自動化程度提高與對高良率的重視，學術界與產業界紛紛投入 AOI 系統之優化研究，涵蓋深度學習演算法、多元影像融合技術與高效特徵擷取方法等方向。本研究即根據此發展趨勢，探討如何整合影像增強、多元資訊融合與 CNN 架構，進一步提升 TFT-LCD AOI 系統在微小瑕疵辨識上的準確性與穩定性，作為智慧製造關鍵技術之一。



1.2 研究目的

本研究旨在探索並實現一種整合多元影像融合之 AOI 瑕疵檢測系統。卷積神經網路（Convolutional Neural Networks, CNN）作為深度學習領域中處理與辨識複雜資料結構的有效技術，尤其在影像辨識、分類與檢測任務方面展現卓越效能，並已廣泛應用於自動化製造與表面瑕疵檢測等眾多領域。

多元影像融合技術能有效彌補單一影像來源的侷限，提升瑕疵檢測的準確性與穩定性。相較之下，單一來源往往無法完整捕捉設備關鍵特徵，而多元融合可提供更全面的影像資訊，強化整體判斷能力。此外，影像增強技術透過亮度與對比度的優化處理，改善原始影像中亮度分布不均與對比度不足的問題，使後續影像處理更為準確。

儘管薄膜電晶體液晶顯示器（Thin-Film Transistor Liquid-Crystal Display, TFT-LCD）技術發展迅速並廣泛應用，其玻璃基板在製程中仍容易產生表面瑕疵，對產品品質造成潛在影響。因此，本研究整合多元影像融合、影像增強技術與卷積神經網路，應用於 TFT-LCD 製造過程中的 AOI 瑕疵檢測。具體而言，本研究設計並規劃一套具備自動化潛力的瑕疵檢測系統，未來可望與實際機台整合，以即時回傳檢測結果至電腦端、人機介面與相關人員，並同步發出預警訊號，進而防止後續作業錯誤，提升整體生產流程之品質與效率。。

1.3 研究原創性、創新性

本研究具備一定程度的原創性與創新性，聚焦於 TFT-LCD AOI 瑕疵檢測領域。隨著科技進步與產業變遷，企業對產品品質的要求日益提高，尤其在生產自動化持續發展下，瑕疵檢測需求益加迫切。本研究結合多元影像融合技術、影像增強方法與深度學習模型，建立一套提升準確性與穩定性的 AOI 瑕疵檢測方法[7]。

為提升檢測系統之可靠度與準確性，研究中採用影像特徵強化搭配深度學習進行瑕疵辨識。透過多元影像資訊融合，能有效強化模型對瑕疵特徵的掌握。多元影像融合技術常應用於不同視角或拍攝條件下所獲得之資料整合，有助於提取互補性特徵，增進分類與辨識精度。然而，由於來源差異導致解析度、光照與拍攝條件不一，特徵表現易產生不一致，進而增加辨識難度，因此，本研究亦著重於融合策略設計以因應此挑戰[8]。

多元影像融合的主要目的為提供更具可靠性與準確性的影像資訊。相較於單一來源影像，融合後之資料往往更具豐富性與代表性，對瑕疵辨識具關鍵性影響。該技術已被廣泛應用於自動目標識別、機器人視覺與各類影像處理領域。

影像增強技術方面，研究中針對原始影像之亮度與對比度進行調整，藉由正規化、裁剪、線性映射與 Gamma 校正等方法，改善亮度分布不均與對比不足的問題，使輸入影像更加清晰，有助於提升模型之辨識準確度。

卷積神經網路（CNN）被視為處理影像中複雜結構的有效技術之一，已廣泛應用於分類、辨識與檢測任務[9,10]。透過微調現有 CNN 架構、設計新型模型，或融合多個 CNN 結構，皆可增強其應用效能，並廣泛應用於瑕疵檢測場景中[11-15]。本研究導入 CNN 技術於 TFT-LCD 製程，以建構一套高效率與高智慧化之瑕疵檢測系統，期能有效提升產品品質並降低生產成本。

YOLO 為一種兼具即時性與準確度之深度學習模型，其採用特徵金字塔網路（Feature Pyramid Network, FPN）架構以提升模型收斂效果。YOLO 已廣泛應用於公共監控、人臉辨識、自動駕駛與表面瑕疵辨識等場域[16-19]，並在多個研究方向中展現優異表現[20-24]。

本研究期望達成以下三項主要目標：

- 提升瑕疵檢測準確性：透過多元影像融合技術提供 CNN 模型更豐富之輸入特徵資訊，輔以影像增強提升影像品質，進一步強化對 TFT-LCD 表面瑕疵之分類與辨識效果。
- 提高檢測效率：CNN 模型具備優異之特徵提取能力與非線性表徵能力，可快速處理大量面板資料，實現即時瑕疵檢測。
- 促進生產過程自動化：整合多元融合與 CNN 架構，有助於實現 AOI 自動化瑕疵檢測，進而降低人力成本、減少人為誤差，全面提升產線效率與產品品質。

第二章 文獻回顧

早期的 TFT-LCD 瑕疵檢測多倚賴人工目視檢查，容易受到主觀判斷與人為疏失的影響，且整體效率較低。隨著機器學習、深度學習與多元影像融合技術的發展，現今已可透過更智慧化的方式提升 AOI 自動化瑕疵檢測的準確性與穩定性。

為了說明本研究所採用之技術基礎與應用背景，本章將依序介紹：第 2.1 節 機器學習、第 2.2 節 深度學習，以及第 2.3 節 多元影像融合。

2.1 機器學習

在2020年，YANG等人設計了影像擷取處理系統，並提出一種基於支援向量機（Support Vector Machine, SVM）的物流包裝箱瑕疵檢測方法（Logistics Packaging box Defect Detection, LPDD）。該方法整合影像預處理與影像增強技術，設計適用於物流包裝影像的去除雜訊與拉普拉斯銳化模板，並提出改良的形態學與灰階邊緣偵測演算法以強化瑕疵特徵。最後，應用尺度不變特徵轉換（Scale-Invariant Feature Transform, SIFT）提取影像特徵，並以 SVM 分類器進行訓練與測試。實驗結果顯示，該方法能有效辨識兩種常見瑕疵，具備良好的準確率與較低的計算成本，展現出在機器視覺檢測領域的應用潛力 [25]，如下圖 2-1 所示。




圖2-1 物流包裝箱瑕疵檢測架構圖[25]

2.2深度學習

在2024年Zhang等人，為了實現實際場景中變電站設備表面各種瑕疵的精確即時檢測與解決原始資料有限的問題。首先使用 ADD-GAN (Abnormal Defect Detection Generative Adversarial Network, ADD-GAN)的方法來增加影像訓練集。此外，本研究提出一種名為YOLO-SD 的目標偵測模型，以偵測複雜實際情境中的各種設備瑕疵。為了增強網路在複雜背景下的特徵萃取能力，並提高偵測準確度，本研究引進了一個名為C3+的新穎深度特徵萃取模組。此外，研究者將 SimAM 整合到 YOLO-SD 的頸部網路中。這種整合不僅增強了網路的學習能力，還使其具備了自主學習和動態微調注意力權重的能力，以適應不同的輸入場景。針對不同變電站設備瑕疵在影像中的大小和形狀變化所帶來的挑戰，設計了新穎的融合損失函數 NWD-CIoU (Normalized Wasserstein Distance - Complete-IoU, NWD-CIoU)。這些改進提升了 YOLO-SD 在不同尺度的瑕疵目標偵測中的精確度和穩定性[26]，如下圖 2-2 所示。




圖2-2 變電所設備瑕疵檢測架構圖[26]

在2024年Jiang等人提出一種基於生成對抗網路（Generative Adversarial Network, GAN）和YOLO算法內部螺紋瑕疵檢測系統。在工業檢測領域，螺紋質量的準確檢測對機械性能至關重要。現有的基於機器視覺的內部螺紋瑕疵檢測方法常面臨由於機械幾何特徵影響而導致的高效檢測和訓練樣本不足的挑戰。研究提出了一種新穎的影像採集結構，並基於GAN提出了一種數據增強算法，以有效構建高質量的訓練集。透過多指標評估，與外部螺紋進行比較，實現了高相似度的內部螺紋影像生成。內部和外部螺紋的檢測準確率分別達到了94.27%和93.92%，有效檢測了內部螺紋瑕疵[27]，如下圖2-3 所示。



圖2-3 基於生成對抗網路（GAN）和 YOLO 算法的內部螺紋瑕疵檢測系統[27]

2.3 多元影像融合

在 2021 年，Li 等人提出融合可見光、偏振與紅外線的多源影像技術，並採用 MobileNetV3 作為輕量化主幹網路，以應用於印刷電路板 (Printed Circuit Board, PCB) 瑕疵檢測。該研究設計多源影像擷取系統，可同時擷取亮度強度、偏振和紅外線資訊，並建立多感測器輕量級檢測網路 (Multisensor Lightweight Detection Network, MLDN)，於所收集的 PCB 資料集上進行訓練。該方法融合可見光與紅外光譜中的偏振與亮度特徵，能有效應對嚴苛照明條件下的瑕疵辨識任務。實驗結果顯示，所提出的網路架構在平均精度方面優於先進的自動光學檢測技術[28]，如下圖 2-4 所示。




圖2-4 多感測器輕量級檢測網路（MLDN）架構圖[28]

在2024年Yu等人提出了一個基於內在特徵分解和多層融合的PCB瑕疵檢測分類模型。首先，使用改進的 Retinex 分解來產生更適合分類任務的多層反射和著色圖。針對反射圖設計了分級稀疏編碼器來表徵影像特徵。接著，使用具有多維變換器的雙邊卷積濾波器來去除著色圖中存在的雜訊資訊。最後透過通道注意力和像素注意力的多層注意力模組進行特徵融合進行分類，提高瑕疵特徵資訊的使用率。透過在不同亮度比的資料集中將所提出的演算法與其他先進演算法進行比較，證明所提出的演算法能夠有效提高PCB瑕疵檢測的準確性[29]，如下圖2-5 所示。




圖2-5 PCB瑕疵檢測模型架構圖[29]

在2021年Guan等人，提出針對傳統網路單一感測器所擷取的資訊和擷取的單尺度特徵不全面的瓶頸，並提出多感測器多尺度模型（2MNet），為準確的故障診斷帶來新的視角。最值得注意的是，可以透過定義新穎的相關峰度加權融合規則來融合三個方向的多感測器振動訊號。此外，多尺度的意義是雙重的：一是透過優化常規深度殘差網路並添加擴張卷積層來提取多尺度特徵，二是結合金字塔原理實現多尺度特徵融合，可以連接深與淺的特徵。數值模擬和滾動軸承數據證實了該模型的優越性和適用性[30]，如下圖2-6所示。




圖2-6 多感測器和多尺度模型架構圖[30]

在2023年Tong等人，為了確保CNN專注於一維訊號中更多的關鍵資訊並減少對其他資訊的關注，提出了一種基於多感測器資訊融合和協調注意力（Coordinated Attention, CA）的新型CNN網路架構，並將其應用於滾動軸承故障診斷。此外，研究者研究了所提出網路的可解釋性，直觀地揭示了所提出網路的特徵學習過程和最終表達形式。首先，提出了適用於一維振動訊號的協調注意力模組，並建立了輕量級協調注意力卷積神經網路模型(Attention Convolution Neural Network, ACNN)。其次，設計了峰度加權融合策略來增強感測器通道的衝擊特性。然後，基於ACNN和加權融合策略，建構了多感測器資訊融合框架。最後，基於多感測器ACNN，提出了一種新的滾動軸承故障診斷方法[31]，如下圖2-7 所示。




圖2-7 基於多感測器ACNN方法的架構圖[31]



第三章 研究方法

本章將說明本研究於 TFT-LCD AOI 瑕疵檢測中所採用的實驗方法。各項方法將依序於第 3.1 節至第 3.7 節中說明。

3.1 研究架構

本節將詳細介紹本研究的整體流程，內容包含影像擷取、影像增強、多元影像融合與卷積神經網路（CNN）建模等流程，整體研究流程如圖 3-1 所示。




圖3-1 實驗架構圖

3.2 影像擷取收集

本研究共蒐集 480 張影像資料，所有影像皆以高解析度數位相機於現場實拍擷取，並在拍攝過程中使用正向光源照明，確保影像具備良好的品質與細節清晰度，以利後續瑕疵辨識模型之訓練與測試。影像來源主要針對工業產品表面，依照瑕疵特徵區分為三類：刮痕、污漬與孔洞，每類別各收集 160 張影像。


為提高資料多樣性與代表性，拍攝樣本涵蓋不同批次、產線與光照條件。影像皆由專業人員進行人工標註，清楚標示瑕疵位置與範圍，並經由兩位以上專家進行複核，以確保標註準確性與一致性。所有影像皆經過預處理，包括尺寸統一、亮度與對比度調整、以及雜訊去除，以提升輸入資料的一致性與模型訓練效果。

影像資料依照 8:2 比例劃分為訓練集與測試集，其中訓練集共 384 張影像（每類別各 128 張），測試集為 96 張影像（每類別各 32 張）。此分配方式可確保每類瑕疵在模型訓練與驗證過程中皆有充分樣本，有助於提升模型對不同類型瑕疵的辨識能力，並能有效評估其泛化性能。

三種瑕疵類型說明如下：

- 刮痕（Scratch）：表面因摩擦或劃傷形成的線狀損傷，常見於金屬或塑膠材質表面。
- 污漬（Contamination）：表面因異物、油污或其他污染造成的區域性變色或髒污，對外觀品質影響較大。
- 孔洞（Hole）：表面出現穿透性瑕疵或凹陷，通常源自製程異常或材料瑕疵。


圖 3-2 顯示三類典型瑕疵影像，作為模型訓練與測試之參考依據。



(a)刮痕



(b)污漬



(c)孔洞

圖3-2影像瑕疵的種類

整體而言，本研究於資料建置過程中，重視影像品質控管與標註正確性，並確保各類別資料分布均衡，成功建構出一組具代表性之瑕疵影像資料集。未來可依據相同流程擴充資料量與瑕疵種類，以進一步提升模型的泛化能力與實務應用價值。

3.3 影像增強

影像亮度與對比度調整的目標是提供更均衡且更準確的視覺呈現效果。相較於直接使用原始影像，經過調整的影像能有效增強細節與對比度，使其更適合後續分析與應用。該技術已廣泛應用於影像增強、醫學影像處理與電腦視覺等領域。實際上，影像中光照不均、對比度不足等問題會對分析結果造成不良影響[32]。影像增強流程圖，如下圖3-3 所示。

正規化像素值 $I_{normalized}$ 的計算如公式(1)所示：

$$I_{normalized} = \frac{I}{255} \quad (1)$$

其中：

I 為原始像素值（範圍 $[0, 255]$ ）。

$I_{normalized}$ 為正規化後的像素值（範圍 $[0, 1]$ ）。

像素值裁剪 $I_{clipped}$ 的計算如公式(2)所示：

$$I_{clipped} = clip(I_{normalized}, low, high) \quad (2)$$

其中：

$I_{clipped}$ 為裁剪後的像素值。

low 分別為輸入像素最低門檻值（範圍 $[0, 0.1]$ ）。

$high$ 分別為輸入像素最高門檻值（範圍 $[0.4, 0.7]$ ）。

$clip(I_{normalized}, low, high)$ 是一個裁剪函數，將 $I_{normalized}$ 限制在範圍 $[low, high]$ 內：

$$\text{clip}(I_{\text{normalized}}, \text{low}, \text{high}) = \begin{cases} \text{low}, & \text{if } I_{\text{normalized}} < \text{low} \\ \text{high}, & \text{if } I_{\text{normalized}} > \text{high} \\ I_{\text{normalized}}, & \text{if } \text{low} \leq I_{\text{normalized}} \leq \text{high} \end{cases}$$

線性映射 I_{rescaled} 將裁剪後的像素值重新映射回 $[0,1]$ ，其計算如公式(3)所示：

$$I_{\text{rescaled}} = \frac{I_{\text{clipped}} - \text{low}}{\text{high} - \text{low}} \quad (3)$$

其中：

I_{rescaled} 為映射後的像素值。

I 的 Gamma 校正 $I_{\text{gamma_corrected}}$ 的計算如公式(4)所示：

$$I_{\text{gamma_corrected}} = I_{\text{rescaled}}^{\gamma} \quad (4)$$

其中：

$I_{\text{gamma_corrected}}$ 為應用 Gamma 校正後的像素值。

Gamma 值，控制對比度的非線性程度：

當 $\gamma > 1$ 時，壓縮暗區細節，增強亮區。

當 $\gamma < 1$ 時，增強暗區細節，壓縮亮區。

當 $\gamma = 1$ 時，不會有任何動作。

像素值轉換為整數格式 I_{output} 的計算如公式(5)所示：

$$I_{\text{output}} = I_{\text{gamma_corrected}} \times 255 \quad (5)$$

其中：

I_{output} 為最終輸出的像素值（範圍 $[0, 255]$ ）。

$\times 255$ 是將值還原到 8 位圖像的標準範圍。




圖3-3 影像特徵增強流程圖

本研究透過影像增強方法強化 TFT-LCD 瑕疵於影像中的顯著特徵，使深度學習模型能更有效地聚焦於異常區域。該方法提升了對各類瑕疵，特別是不明顯瑕疵的檢測能力，進一步改善分類與定位的準確性，並降低模型在複雜背景下的誤判風險。

3.4 多元影像融合

多元影像融合的目標是提供更可靠且更準確的數據表現。相較於單一影像來源所獲取的數據，多元影像資訊通常包含互補特徵訊息，這些特徵訊息在瑕疵檢測中極具價值。

目前，多元影像融合技術已廣泛應用於自動目標識別、機器人技術和影像處理等領域。實際上，在生產線中會有各種的產品瑕疵狀況，進而導致生產過程中不良率提升。在感測與影像擷取技術快速發展的背景下，已有部分研究採用多來源影像資訊進行瑕疵檢測，進一步提升瑕疵辨識的準確性與診斷效果 [28,29]。

本研究採用多元影像融合技術，將來自兩個不同來源的影像進行融合，以提升瑕疵特徵的表現力。假設 $x_1(n)$ 、 $x_2(n)$...、 $x_k(n)$ 分別代表由 k 個不同影像來源所擷取之影像特徵，則本研究中 $x_p(n)$ 與 $x_q(n)$ 分別代表由兩個不同來源的影像資料(原始影像與增強影像)，並設定 $k=2$ 。其中， n 表示第 n 個特徵的位置， N 為每張影像的總像素數量 [30]。

原始影像 p 與增強影像 q 之間的相關性 $R_{p,q}$ 如公式(6)所示：

$$R_{p,q} = \frac{1}{N} \sum_{n=1}^N x_p(n)x_q(n) \quad (6)$$

原始影像 p 與增強影像 q 所對應特徵之間的關聯強度 $E_{p,q}$ 如公式(7)所示：

$$E_{p,q} = \sum_{n=1}^N [R_{p,q}(n)]^2 \quad (7)$$

原始影像 p 與增強影像 q 之間的總體相關性，定義總相關能量 E_p 如公式(8)所示：

$$E_p = \sqrt{\sum_{q=1, q \neq p}^k E_{p,q}^2} \quad (8)$$

峰度(Kurtosis)指數 K_p 的計算如公式(9)所示：

$$K_p = \frac{\frac{1}{N} \sum_{n=1}^N [x_p(n) - \mu]^4}{\left(\frac{1}{N} \sum_{n=1}^N [x_p(n) - \mu]^2 \right)^2} \quad (9)$$

其中， μ 表示影像灰階特徵的平均值。

根據總相關能量與峰度指數，可計算出原始影像 p 的融合權重 W_p 如公式(10)所示：

$$W_p = \frac{E_p * K_p}{\sum_{p=1}^k E_p * K_p} \quad (10)$$

最後，融合特徵 Y 表示如公式(11)所示：

$$Y = \sum_{p=1}^k W_p \cdot x_p(n) \quad (11)$$

3.5 卷積神經網路(Convolutional Neural Network, CNN)

本研究以卷積神經網路為主要方法，旨在訓練高準確度的瑕疵分類與預測模型，並採用不同的神經網路架構應用於TFT-LCD AOI瑕疵檢測與分類任務中。卷積神經網路（Convolutional Neural Network, CNN）是一類在影像識別領域中被廣泛應用的深度學習模型。其架構具有層次化的特性，主要由卷積層與池化層組成，可從輸入影像中逐層提取有意義的特徵。經特徵提取後，模型會透過一系列全連接層（Fully Connected, FC）進行分類或預測。

CNN 的應用通常需經過初步訓練階段，訓練資料集須包含大量已標註之影像，並著重於影像中的關鍵區域。模型在此階段透過反覆的參數調整與誤差反向傳播，學習將輸入影像特徵與正確標籤進行對應，並利用優化演算法進行學習。

當 CNN 訓練完成並達到穩定效能後，便可應用於未知影像的分類任務。在推論階段，輸入影像會被送入模型，CNN 會自動識別並分析其特徵，最終輸出具有最高預測機率之分類結果。此一架構展現了 CNN 在影像識別任務中的有效性與實用價值[33]。CNN基本架構圖，如下圖3-4 所示。




圖3-4 CNN 基本架構圖[33]

CNN 通常由多個層次組成，每個層次在網路中扮演著不同且重要的角色。以下將說明卷積層、池化層、激勵函數的功能與作用：

卷積層 (Convolutional Layer)：卷積層是CNN架構中的基礎核心，由一組卷積核（也稱為濾波器）組成，這些濾波器在從輸入影像中提取特徵的過程中扮演關鍵角色。卷積核會在影像上滑動，將其劃分為稱為感受野的較小矩陣。這種影像分割有助於提取獨特的特徵模式。卷積運算會將卷積核滑過影像，並對感受野中的像素進行逐元素相乘，生成一個特徵圖，其中每個像素代表特定濾波器在影像中某位置的響應值。卷積之運算如公式(12)所示：

$$y^{l(i,j)} = K_i^l * X^{l(r^j)} = \sum_{j'=0}^{W-1} K_i^{l(j')} X^{l(j+j')} \quad (12)$$

其中*符號表示卷積運算； $K_i^{l(j')}$ 表示第 l 層中，第 i 個卷積核的第 j' 個權重值； $X^{l(r^j)}$ 則代表第 l 層中，第 j 個被卷積的區域；而 W 表示卷積核的寬度。

池化層 (Pooling Layer)：池化層通常位於卷積層之後。池化層可以減少卷積層輸出的資訊，並降低特徵映射的維度。經典池化操作有兩種：最大池化與平均池化。最大池化是以資料區塊中的最大值作為輸出，擷取特徵平面的最大響應；而平均池化則是將區塊中元素的算術平均作為輸出，並提取特徵平面的局部對應平均值。最大池化的特點是保留影像中的結構特徵，而平均池化則保留整體資料的特徵。

最大池化 (Max Pooling)之運算如公式(13)所示：

$$p^l(i,j) = \max_{(j-1)W+1 \leq t \leq jW} \{a^l(i,t)\} \quad (13)$$

平均池化 (Average Pooling) 之運算如公式(14)所示：

$$q^l(i,j) = \frac{1}{W} \sum_{(j-1)W+1 \leq t \leq jW} a^l(i,t) \quad (14)$$

$a^l(i,j)$ 表示第 l 層特徵圖中，第 i 行、第 t 列的啟用值 (Activation)。

$(j-1)W + 1 \leq t \leq jW$ 表示池化窗口的範圍，窗口大小為 W 。

最大池化操作在每個池化窗口內選擇啟用值的最大值，作為該窗口的池化輸出 $p^l(i,j)$ 。

平均池化通過對每個池化窗口內的啟用值進行求和並取平均，獲得池化輸出 $q^l(i,j)$ 。

激勵函數：激勵函數是神經網路的重要組成部分，它可以提高模型的非線性表達能力。激勵函數分為線性激勵函數和非線性激勵函數。根據不同情況可以使用 sigmoid、tanh、ReLU 等不同類型的激勵函數。其中，sigmoid 函數之運算如公式(15)所示：

$$\sigma(y^{l(i,j)}) = 1/(1 + e^{-y^{l(i,j)}}) \quad (15)$$

$\sigma(y^{l(i,j)})$ 的範圍是 0-1。當網路的最終目標是預測機率時，可應用於輸出層。

tanh 函數的激勵函數也被稱為雙曲正切函數。與 sigmoid 函數類似，tanh 也將實數壓縮到一個範圍內。不同於 sigmoid，tanh 的輸出範圍是從 -1 到 1，並且具有均值為零。其中，tanh 函數之運算如公式(16)所示：

$$\tanh(y^{l(i,j)}) = \frac{e^{y^{l(i,j)}} - e^{-y^{l(i,j)}}}{e^{y^{l(i,j)}} + e^{-y^{l(i,j)}}} \quad (16)$$

tanh 函數與 sigmoid 函數都有梯度消失問題。為了解決梯度消失的問題，線性整流函數（ReLU）的非線性激活函數有效地解決了這一問題。與這兩種激活函數相比，ReLU 表現更好，並且如今是最廣泛使用的激活函數。其中，ReLU 函數之運算如公式(17)所示：

$$f(y^{l(i,j)}) = \max(0, (y^{l(i,j)})) \quad (17)$$

非線性表示變量第一導數。ReLU 函數表示為 $\max(0, x)$ ，因此產生其導數如公式(18)所示：

$$f'(y^{l(i,j)}) = \begin{cases} 0, & \text{for } y^{l(i,j)} < 0 \\ 1, & \text{for } y^{l(i,j)} \geq 0 \end{cases} \quad (18)$$

3.5.1 MobileNetV3 網路

MobileNet 網路透過深度可分離卷積（Depthwise Separable Convolution）來實現卷積層的輕量化。深度可分離卷積由深度卷積（Depthwise Convolution）與逐點卷積（Pointwise Convolution）組成。與標準卷積不同，深度卷積會針對每個輸入通道上獨立執行卷積運算，且卷積核數量與輸入通道數相同；而逐點卷積則使用 1×1 的卷積核，對深度卷積所得之特徵圖進行卷積，以實現各通道特徵的線性組合與融合。與標準卷積相比，深度可分離卷積可大幅減少模型參數與計算量，進而提升整體運算效率量 [34]。

3.5.2 訓練數據集

本研究採用 MobileNetV3 作為主要網路架構，該模型為一種輕量級深度卷積神經網路，具備參數量少、運算效率高的特性。訓練階段則基於預先於大型資料集上訓練的權重進行微調，以加速收斂並降低訓練所需的計算資源。MobileNetV3 為一種輕量級深度神經網路，適合應用於需要快速計算與低延遲的任務上。

在實驗設計方面，本研究採用 Batch Size 為 32、初始學習率為 0.01 進行模型訓練，並分別設定 200、300、400 與 500 個訓練週期（Epoch）進行多組實驗，以觀察訓練次數對模型收斂速度與分類效能之影響。我們將目標瑕疵影像資料輸入至預先於大型資料集上訓練完成之 MobileNetV3 模型，使其能有效處理本研究之瑕疵分類任務。此方法不僅有助於提升模型準確率，也可縮短訓練時間並降低參數調整的複雜度。

MobileNetV3 架構模組主要透過整合輕量化設計與效率導向的技術來強化模型效能，核心技術包括：

- 深度可分離卷積（Depthwise Separable Convolution）：有效降低模型的運算量與參數數量，並保留充足的特徵表達能力。
- Squeeze-and-Excitation 注意力機制：可自動聚焦於影像中細微且關鍵瑕疵，提升辨識準確度。
- Hard-Swish 激活函數：此函數強化了模型對複雜特徵的非線性擬合能力，有助於提升分類準確度。

因此，MobileNetV3 架構在 TFT-LCD 或其他瑕疵檢測任務中，能兼顧運算效率與準確性，展現優異的應用潛力[35]。MobileNetV3 架構模組（MobileNetV3-block）如圖 3-5 所示，Squeeze-and-Excitation 注意力機制則如圖 3-6 所示。




圖3-5 MobileNetV3 架構模組（MobileNetV3-block）[35]

Squeeze-and-Excitation 注意力機制：

以增強模型對重要特徵通道的響應能力，進一步提升分類與辨識準確率。假設輸入特徵圖為 X ，大小為 $C \times H \times W$ （ C 是通道數、 H 與 W 是高寬）[36]：

Squeeze (擠壓)，如(19)：

$$Z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_c(i, j), \quad Z_c \in R^C \quad (19)$$

Excitation (激勵)，如(20)：

$$S = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot Z)) \quad (20)$$

特徵重新校準 (Recalibration)，如(21)：

$$X' = X \times S \quad (21)$$

其中：

Z_c ：全局平均池化的結果，代表每個通道的全局資訊。

W_1, W_2 ：可學習的參數（全連接層的權重）。

W_1 會將 Z 的維度從 C 縮減到 C/r （ r 為縮減率，通常為 16），以減少模型複雜度。

W_2 會將維度從 C/r 恢復到 C 。

σ ：Sigmoid 函數，輸出 0~1 間的權重。

X' ：重新調整後的特徵圖。




圖3-6 Squeeze-and-Excitation 注意力機制 [36]

Hard-Swish 激活函數：

在 MobileNetV3 中，為了同時兼顧非線性表現能力與運算效率，提出了 Hard-Swish 激活函數（Hard-Swish Activation Function），作為 ReLU 及 Swish 函數的替代方案[35]。該函數可表示如(22)：

$$HardSwish(x) = x \cdot \frac{ReLU6(x + 3)}{6} \quad (22)$$

其中 $ReLU6(x) = \min(\max(0, x), 6)$ 為限制在 $[0, 6]$ 範圍的 ReLU 函數。

本網路架構結合了 MobileNetV3 高效且精準的特性，尤其適合於影像瑕疵檢測任務，透過 SE 注意力機制與輕量化設計，能有效地捕捉與判斷細微的瑕疵特徵，提升模型檢測的準確性與可靠性[35]。

MobileNetV3 模型結構，如下表 3-1 所示。

表 3- 1 MobileNetV3 模型結構 [35]

Block / Layer	輸入→輸出 通道數	卷積核 大小	步長 (stride)	激活函數	SE 模組	殘差 連接
1. Conv2d + BN	3 → 16	3×3	2	HardSwish	X	√
2. MobileNetV3 Block	16 → 16	3×3	1	ReLU	X	√
3. MobileNetV3 Block	16 → 24	3×3	2	ReLU	X	X
4. MobileNetV3 Block	24 → 24	3×3	1	ReLU	X	√
5. MobileNetV3 Block	24 → 40	5×5	2	HardSwish	√	X
6. MobileNetV3 Block	40 → 40	5×5	1	HardSwish	√	√
7. MobileNetV3 Block	40 → 80	3×3	2	HardSwish	X	X
8. MobileNetV3 Block	80 → 112	3×3	1	HardSwish	√	X
9. MobileNetV3 Block	112 → 160	5×5	2	HardSwish	√	X
10. Conv2d (1 × 1) + BN	160 → 960	1 × 1	1	-	X	X
11. Global Average Pooling	960 → 960	-	-	-	X	-
12. BatchNorm1d	960 → 960	-	-	-	X	-
13. Dropout 0.2	-	-	-	-	X	-
14. FC	960 → num_classes	-	-	-	X	-

3.6 評估指標

為評估深度學習模型之訓練效果與預測表現，本研究以準確率（Accuracy）、精確率（Precision）、召回率（Recall）以及 F1-Score 作為主要評估指標，其定義如下：

3.6.1 準確率(Accuracy)

評估模型預測的整體正確性的指標。如公式(23)所示：

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \quad (23)$$

3.6.2 精確率(Precision)

評估模型預測為陽性的樣本中真正陽性樣本比例的指標。如公式(24)所示：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (24)$$

3.6.3 召回率(Recall)

評估模型預測正樣本的準確性。如公式(25)所示：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (25)$$

3.6.4 F1-Score

F1-Score 定義為精確率(Precision)和召回率(Recall)的調和平均值，用以衡量模型的準確性和穩定性。如公式(26)所示：

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (26)$$

3.7 混淆矩陣

本實驗在模型訓練中，利用混淆矩陣來評估模型的效能。混淆矩陣中，左上與右下的部分代表正確的預測結果，而右上與左下則代表錯誤的預測結果。TP 表示預測為陽性且實際亦為陽性，也就是圖像確有瑕疵且被正確檢出；FP 為偽陽性，表示預測為陽性但實際並無瑕疵，即模型誤報；FN 表示偽陰性，即圖像有瑕疵但模型未能捕捉到；TN 為真陰性，即圖像無瑕疵且模型的判斷正確。透過這種方式，我們能夠全面評估模型在不同情境下的預測表現，如表3-2 所示。



表3- 2 混淆矩陣

Actual \ Predict	Positive	Negative
Positive	Ture Positive, TP	False Positive, FP
Negative	False Negative, FN	True Negative, TN

因本研究有三種瑕疵類別，故混淆矩陣為 3×3 ，示意圖如表3-3 所示：

表3- 3 本研究實際應用之混淆矩陣示意圖

Predict Actual	刮痕	孔洞	污漬
刮痕	TP_1	FN_2	FN_3
孔洞	FN_1	TP_2	FN_3
污漬	FN_1	FN_2	TP_3

表 3-3 中所呈現的混淆矩陣是基於二元分類方式所繪製，但在本任務中共有三個類別，因此我們需要分別列出模型在各類別中的預測指標。這種多類別混淆矩陣可以更清楚地呈現模型在每類別上的分類性能，並確保對所有類別進行全面評估。

第四章 研究成果

4.1 實驗設備

本研究所有實驗皆於統一之軟硬體設備下進行，以確保實驗結果之可重現性與比較基準之一致性。硬體配置方面，本研究採用配備 Intel(R) Core(TM) i9-14900KF 中央處理器、NVIDIA GeForce RTX 4090 繪圖處理器，並搭載 64 GB 記憶體之工作站電腦。軟體部分，作業系統為 Windows 11，所有程式碼皆透過 Python 3.12.8 版本進行開發與執行。

4.2 影像增強處理

本節將依序說明影像增強預處理（4.2.1 節）的具體流程，以及其於訓練階段所產生的影像增強訓練結果（4.2.2 節）。

4.2.1 影像增強預處理

在影像增強技術領域，調整影像亮度與對比度是關鍵功能之一。此技術能有效解決影像中亮度分佈不均勻及對比度不足的問題，進而大幅提升整體影像處理工作流程的精確性與準確性。

由於原始影像的像素分佈常缺乏必要的細節呈現，因此這些進階技術採用一系列方法步驟。這包括但不限於正規化 (Normalization)、裁剪 (Clipping)、線性映射 (Linear Mapping) 與 Gamma 校正 (Gamma Correction) 等。這些步驟共同運作，旨在提供更豐富且視覺效果更佳的亮度與對比資訊呈現。

此類影像增強方法能系統性地應用於各種場景與環境，以顯著提升視覺效果，展現其在多個領域中強大的應用潛力。本實驗影像增強結果：(a) 原始影像 (b) 增強影像，如下圖4-1 所示。




圖4-1 影像增強結果

4.2.2 影像增強訓練結果

如圖 4-2 所示，本研究模型於不同訓練週期（Epochs）下，導入影像增強技術後之各項評估指標表現。整體而言，這些指標在各訓練週期中均維持於 80% 上下之水平。






圖4-2 影像增強的訓練結果


EPOCHS 200 BATCH_SIZE 32 LEARNING_RATE 0.01



(c)

圖4-3 EPOCHS 200 BATCH_SIZE 32 LEARNING_RATE 0.01
(a) Accuracy (b) Loss (c) Confusion Matrix

EPOCHS 300 BATCH_SIZE 32 LEARNING_RATE 0.01






圖4-4 EPOCHS 300 BATCH_SIZE 32 LEARNING_RATE 0.01
(a) Accuracy (b) Loss (c) Confusion Matrix

EPOCHS 400 BATCH_SIZE 32 LEARNING_RATE 0.01





圖4-5 EPOCHS 400 BATCH_SIZE 32 LEARNING_RATE 0.01
(a) Accuracy (b) Loss (c) Confusion Matrix

EPOCHS 500 BATCH_SIZE 32 LEARNING_RATE 0.01




圖4-6 EPOCHS 500 BATCH_SIZE 32 LEARNING_RATE 0.01
(a) Accuracy (b) Loss (c) Confusion Matrix

4.3 影像融合處理

本節將依序說明影像融合預處理（4.3.1 節）的具體流程，以及其於訓練階段所呈現的影像融合訓練結果（4.3.2 節）。

4.3.1 影像融合預處理

在多元影像融合方面，透過整合來自不同影像來源的互補性數據，可顯著提升瑕疵檢測的準確度與可靠性。相較於單一影像來源所獲取的數據，多元影像融合能提供更全面的特徵呈現，特別是在處理複雜瑕疵類型時（如刮痕、污漬等）。這些融合結果不僅能有效降低單一數據源可能存在的誤差，也能強化瑕疵檢測中的靈敏度和穩定性。影像融合過程：(a) 原始影像 (b) 增強影像 (c) 影像融合，如下圖4-7 所示。

透過進一步分析，驗證多元影像融合訊息在提升瑕疵檢測效率與精度方面的潛力，也為後續進一步優化影像融合演算法提供了有力的基礎。




圖4-7 影像融合過程

4.3.2 影像融合訓練結果

如圖 4-8 所示，本研究模型在不同訓練週期（Epochs）下，導入影像融合技術後的各項評估指標表現。整體而言，這些指標在不同訓練週期下均維持在 85% 上下之水平，顯示模型在經過影像融合處理後，具備穩定且良好的瑕疵檢測效能。




圖4-8 影像融合的訓練結果

如圖 4-9 所示，本研究模型之測試準確率在訓練過程中呈現較大波動。由於資料集中微小瑕疵之特性，這些瑕疵的細微且特徵不明顯，使得預測表現呈現不穩定或準確率起伏。

EPOCHS 200 BATCH_SIZE 32 LEARNING_RATE 0.01







圖4-9 EPOCHS 200 BATCH_SIZE 32 LEARNING_RATE 0.01



(a) Accuracy (b) Loss (c) Confusion Matrix

EPOCHS 300 BATCH_SIZE 32 LEARNING_RATE 0.01





(c)
圖4-10 EPOCHS 300 BATCH_SIZE 32 LEARNING_RATE 0.01
(a) Accuracy (b) Loss (c) Confusion Matrix
EPOCHS 400 BATCH_SIZE 32 LEARNING_RATE 0.01



(c)
圖4-11 EPOCHS 400 BATCH_SIZE 32 LEARNING_RATE 0.01
(a) Accuracy (b) Loss (c) Confusion Matrix

EPOCHS 500 BATCH_SIZE 32 LEARNING_RATE 0.01




圖4-12 EPOCHS 500 BATCH_SIZE 32 LEARNING_RATE 0.01

(a) Accuracy (b) Loss (c) Confusion Matrix

目前，實驗結果顯示，基於多元影像的融合技術能顯著改善以下幾方面的指標：

- 檢測準確率：融合後的結果在多瑕疵情境下平均準確率提升了約2~5%。
- 穩定性：對於邊緣模糊或對比度低的微小瑕疵，融合技術展現出更高的檢測一致性。
- 應用環境適應性：根據相關研究，若結合不同來源的影像數據（如可見光與紅外線），可使瑕疵特徵表現更清晰，進而提升模型於多種生產場景中的適應性。

4.4 訓練實驗結果

本節將說明各項影像處理方法導入後之比較結果，詳細數據整理如表 4-1 至表 4-3 所示。。

根據實驗結果，為驗證不同影像預處理來源對於模型效能之影響，本研究依序導入各項影像處理技術，觀察模型準確率的變化，並評估各處理流程的貢獻程度。實驗計劃包含三個階段：原始影像（Original Image）、影像增強（Image Enhancement）以及影像融合（Image Fusion）。

原始影像（Original Image）

直接以未經處理的原始影像進行訓練。其詳細訓練結果如表 4-1 所示。

表4- 1 原始影像的訓練結果

EPOCHS	BATCH SIZE	LEARNING RATE	F1 Score	Precision	Recall	Accuracy
200	32	0.01	74.62%	75.05%	75.00%	75.00%
300	32	0.01	75.59%	75.61%	76.04%	76.04%
400	32	0.01	72.55%	73.78%	72.92%	72.91%
500	32	0.01	71.77%	72.48%	71.88%	71.87%

影像增強 (Image Enhancement)

對原始影像進行前處理與增強（如對比度提升、降噪、亮度調整等），再進行模型訓練。其詳細訓練結果如表 4-2 所示。

表4- 2 影像增強的訓練結果

EPOCHS	BATCH SIZE	LEARNING RATE	F1 Score	Precision	Recall	Accuracy
200	32	0.01	81.14%	81.07%	81.14%	81.25%
300	32	0.01	79.93%	80.27%	80.20%	80.19%
400	32	0.01	79.79%	80.32%	80.20%	80.21%
500	32	0.01	79.94%	80.15%	80.21%	80.21%

影像融合 (Image Fusion)

將原始影像與增強影像進行融合，以整合兩者特徵並建構更完整之資料集。其詳細訓練結果如表 4-3 所示。

表4- 3 影像融合的訓練結果

EPOCHS	BATCH SIZE	LEARNING RATE	F1 Score	Precision	Recall	Accuracy
200	32	0.01	87.44%	87.26%	87.50%	87.50%
300	32	0.01	88.04%	88.08%	88.12%	87.50%
400	32	0.01	86.00%	85.83%	86.12%	86.21%
500	32	0.01	84.90%	84.93%	84.98%	84.93%

根據實驗結果，本研究透過影像增強與影像融合預處理，有效提升了瑕疵檢測模型之效能。相較於原始影像之 75% 準確率，經影像增強後約可達 80%；而影像融合更將準確率提升至 85% 上下，顯示其對模型判別能力具顯著貢獻。其中，依表4-4所示，在訓練週期（Epochs）為 200、批次大小（Batch Size）為 32、學習率（Learning Rate）為 0.01 的參數設定下，影像融合策略對模型表現的提升顯著。

表4-4 模型於各影像處理階段之效能評估結果

比較項目	F1 Score	Precision	Recall	Accuracy
原始影像	74.62%	75.05%	75.00%	75.00%
影像增強	81.14%	81.07%	81.14%	81.25%
影像融合	87.44%	87.26%	87.50%	87.50%

綜合上述，隨著影像處理技術的逐步引入，模型效能呈現穩定提升，驗證了各處理步驟在瑕疵分類任務中的正向影響。

第五章 結論

本研究構建了一套「基於影像特徵強化與深度學習的 AOI 瑕疵檢測系統」，整體架構主要由影像增強處理、多元影像融合、以及深度學習網路三個核心部分所構成，彼此互為支撐以提升整體檢測效能與系統穩定性。

在影像預處理方面，本研究針對工業檢測中常見的光照不均、對比度不足等挑戰，開發出適應性影像增強演算法。透過動態調整亮度與對比度參數，系統能夠有效抑制影像雜訊並突顯瑕疵特徵。多元影像融合技術的導入，實現了不同影像特徵訊號的有效整合，將融合結果以二維矩陣形式呈現，顯著提升了系統對細微瑕疵的感知能力。

在深度學習模型方面，本研究運用 MobileNetV3 架構進行訓練，整合了二維卷積層、批次正規化、HardSwish 激活函數等技術模組，並搭配注意力機制區塊與自適應平均池化層。這種架構在準確性與運算效率間取得了理想平衡，特別適合工業現場的即時檢測需求。對於邊界模糊、對比度低或尺寸極小等難以察覺的瑕疵，本系統在實驗中已達到近 90% 的辨識準確率。

從實務應用角度來看，本研究建立的自動化檢測流程具有重要的工業價值。系統整合了從影像增強、多元影像融合到最終分類預測的完整處理鏈，實現了端到端自動化檢測。特別值得強調的是，本系統在處理人眼難以察覺的微小瑕疵方面展現出優異性能，能夠有效識別傳統人工檢測無法發現的細微瑕疵，為高精密製造業提供了實用且有效的檢測解決方案。

第六章 未來工作

在本研究中，結合多元影像融合技術、影像增強處理與卷積神經網路（Convolutional Neural Network, CNN）模型，應用於 TFT-LCD AOI 瑕疵檢測任務，並於實驗階段驗證其在細微瑕疵辨識方面之可行性。實驗結果顯示，本研究方法具備進一步應用之潛力，未來可持續優化模型架構與流程設計，以進一步提升瑕疵判斷之穩定性與準確率。

未來工作方面，仍有多項方向可進一步探討與延伸：

1. 模型輕量化與推論效能優化：可針對模型結構進行簡化與調整，以降低運算資源需求，提升在資源有限環境下的適用性。
2. 資料多樣性與類別擴充：現階段樣本以典型瑕疵為主，未來可擴充更多產線資料，以提升模型泛化能力。
3. 跨平台應用與現場整合驗證：後續可評估系統於不同生產環境下之適應性，並強化與實際機台控制系統之整合能力，進一步提升整體系統的實用價值。

透過上述未來發展方向的持續優化與研究，本研究所提出之深度學習瑕疵檢測架構，將能更有效應對多樣化的工業檢測需求，並為智慧製造領域帶來更高的品質控制效率。

參考文獻

- [1] Q. Ling and N. A. M. Isa, “Printed Circuit Board Defect Detection Methods Based on Image Processing, Machine Learning and Deep Learning: A Survey,” *IEEE Access*, vol. 11, PP. 15921-15944, 2023.
- [2] Y. Li and J. Li, “An End-to-End Defect Detection Method for Mobile Phone Light Guide Plate via Multitask Learning,” *IEEE Transactions on Instrumentation and Measurement*, vol. 70, PP. 1-13, 2021.
- [3] C. Li, A. Xu, Q. Zhang and Y. Cai, “Steel Surface Defect Detection Method Based on Improved YOLOX,” *IEEE Access*, vol. 12, PP. 37643-37652, 2024.
- [4] M. Li, H. Wang, Z. Wan, “Surface Defect Detection of Steel Strips Based on Improved YOLOv4,” *Computers and Electrical Engineering*, vol 102, 2022.
- [5] H. Yang, S. Mei, K. Song, B. Tao and Z. Yin, “Transfer-Learning-Based Online Mura Defect Classification,” *IEEE Transactions on Semiconductor Manufacturing*, vol. 31, no. 1, PP. 116-123, Feb. 2018.
- [6] C. -F. Chien and S. -C. Chuang, “A Framework for Root Cause Detection of Sub-Batch Processing System for Semiconductor Manufacturing Big Data Analytics,” *IEEE Transactions on Semiconductor Manufacturing*, vol. 27, no. 4, PP. 475-488, Nov. 2014.
- [7] H. -I. Lin and F. S. Wibowo, “Image Data Assessment Approach for Deep Learning-Based Metal Surface Defect-Detection Systems,” *IEEE Access*, vol. 9, PP. 47621-47638, 2021.
- [8] L. Jing, T. Wang, M. Zhao and P. Wang, “An Adaptive Multi-Sensor Data Fusion Method Based on Deep Convolutional Neural Networks for Fault Diagnosis of Planetary Gearbox,” *Sensors*, 17, 414, 2017.

- [9] Q. Ling and N. A. M. Isa, "Printed Circuit Board Defect Detection Methods Based on Image Processing, Machine Learning and Deep Learning: A Survey," *IEEE Access*, vol. 11, pp. 15921-15944, 2023.
- [10] Y. He, J. Wu, Y. Zheng, Y. Zhang and X. Hong, "Track Defect Detection for High-Speed Maglev Trains via Deep Learning," *IEEE Transactions on Instrumentation and Measurement*, vol. 71, no. 3506008, PP. 1-8, Art. 2022.
- [11] Y. Zhao, K. Hao, H. He, X. Tang, B. Wei, "A Visual Long-Short-Term Memory Based Integrated CNN Model for Fabric Defect Image Classification," *Neurocomputing*, vol 380, PP. 259-270, 2020.
- [12] R. Wang, Q. Guo, S. Lu and C. Zhang, "Tire Defect Detection Using Fully Convolutional Network," *IEEE Access*, vol. 7, PP. 43502-43510, 2019.
- [13] H. Xie, Y. Zhang and Z. Wu, "Fabric Defect Detection Method Combing Image Pyramid and Direction Template," *IEEE Access*, vol. 7, PP. 182320-182334, 2019.
- [14] S. Mei, Y. Wang and G. Wen, "Automatic Fabric Defect Detection with a Multi-Scale Convolutional Denoising Autoencoder Network Model," *Sensors*, 18, 1064, 2018.
- [15] H. Perez, J. H. M. Tah and A. Mosavi, "Deep Learning for Detecting Building Defects Using Convolutional Neural Networks," *Sensors*, 19, 3556, 2019.
- [16] J. Fu, L. Cao, S. Wei, M. Xu, Y. Song, H. Li, Y. You, "A GAN-Based Deep Enhancer for Quality Enhancement of Retinal Images Photographed by a Handheld Fundus Camera," *Advances in Ophthalmology Practice and Research*, vol 2, Issue 3, 100077, 2022.
- [17] J. Liu, C. Wang, H. Su, B. Du and D. Tao, "Multistage GAN for Fabric Defect Detection," *IEEE Transactions on Image Processing*, vol. 29, PP. 3388-3400, 2020.

- [18] X. Li, S. Xue, Z. Li, X. Fang, T. Zhu and C. Ni, “A Candy Defect Detection Method Based on StyleGAN2 and Improved YOLOv7 for Imbalanced Data,” *Foods*, 13, 3343, 2024.
- [19] F. Xing, X. Yang, T. C. Cornish, D. Ghosh, “Learning with Limited Target Data to Detect Cells in Cross-Modality Images,” *Medical Image Analysis*, vol 90, 102969, 2023.
- [20] X. He, Z. Luo, Q. Li, H. Chen and F. Li, “DG-GAN: A High Quality Defect Image Generation Method for Defect Detection,” *Sensors*, 23, 5922, 2023.
- [21] Z. Ni, W. Yang, S. Wang, L. Ma and S. Kwong, “Towards Unsupervised Deep Image Enhancement With Generative Adversarial Network,” *IEEE Transactions on Image Processing*, vol. 29, PP. 9140-9151, 2020.
- [22] C. D. Prakash and L. J. Karam, “It GAN Do Better: GAN-Based Detection of Objects on Images With Varying Quality,” *IEEE Transactions on Image Processing*, vol. 30, PP. 9220-9230, 2021.
- [23] D. Yoon, H. J. Kong, B. S. Kim, et al, “Colonoscopic Image Synthesis with Generative Adversarial Network for Enhanced Detection of Sessile Serrated Lesions Using Convolutional Neural Network,” *Sci Rep*, 12, 261, 2022.
- [24] M. A. Souibgui and Y. Kessentini, “DE-GAN: A Conditional Generative Adversarial Network for Document Enhancement,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, PP. 1180-1191, March. 2022.
- [25] X. Yang, M. Han, H. Tang, Q. Li and X. Luo, “Detecting Defects With Support Vector Machine in Logistics Packaging Boxes for Edge Computing,” *IEEE Access*, vol. 8, PP. 64002-64010, 2020.

- [26] N. Zhang, G. Yang, D. Wang, F. Hu, H. Yu and J. Fan, “A Defect Detection Method for Substation Equipment Based on Image Data Generation and Deep Learning,” *IEEE Access*, vol. 12, PP. 105042-105054, 2024.
- [27] Z. Jiang, X. Dou, X. Liu, C. Xue, A. Wang and G. Zhang, “Internal Thread Defect Generation Algorithm and Detection System Based on Generative Adversarial Networks and You Only Look Once,” *Sensors*, 24, 5636, 2024.
- [28] M. Li, N. Yao, S. Liu, S. Li, Y. Zhao and S. G. Kong, “Multisensor Image Fusion for Automated Detection of Defects in Printed Circuit Boards,” *IEEE Sensors Journal*, vol. 21, no. 20, PP. 23390-23399, Oct. 2021.
- [29] X. Yu, L. Han-Xiong and H. Yang, “PCB Defect Detection Model Based on Intrinsic Feature Decomposition and Multilevel Fusion Against Image Uncertainty,” *IEEE Sensors Journal*, vol. 24, no. 12, PP. 19497-19505, June. 2024.
- [30] Y. Guan, Z. Meng, D. Sun, J. Liu, F. Fan, “2MNet: Multi-Sensor and Multi-Scale Model Toward Accurate Fault Diagnosis of Rolling Bearing,” *Reliability Engineering & System Safety*, vol 216, 108017, 2021.
- [31] J. Tong, C. Liu, J. Zheng, H. Pan, “Multi-Sensor Information Fusion and Coordinate Attention-Based Fault Diagnosis Method and Its Interpretability Research,” *Engineering Applications of Artificial Intelligence*, vol 124, 106614, 2023.
- [32] C. Li, S. Tang, J. Yan and T. Zhou, “Low-Light Image Enhancement via Pair of Complementary Gamma Functions by Fusion,” *Access*, vol. 8, PP. 169887-169896, 2020.

- [33] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” in *Advances in Neural Information Processing Systems 25*, F. Pereira, C. J. C. Burges, L. Bottou, and K. Q. Weinberger, Eds. Curran Associates, 2012.
- [34] A. G. Howard et al., “MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications,” *arXiv preprint arXiv:1704.04861*, 2017.
- [35] A. Howard et al., “Searching for MobileNetV3,” *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, pp. 1314-1324, Oct. 2019.
- [36] J. Hu, L. Shen and G. Sun, “Squeeze-and-Excitation Networks,” *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, Salt Lake City, UT, USA, pp. 7132-7141, 2018.

